

哈爾濱工業大學

模式识别与深度学习实验报告

实验 一

题	目	多项式拟合正弦曲线实验
学	院	未来技术学院
专	业	人工智能
学	号	2024111598
学	生	卢思吉
任	课 教 师	刘扬

哈尔滨工业大学计算机科学与技术学院

2021 年春季

实验内容

1.1 实验任务

本次实验的任务是，先对 $y = \sin(\pi x)$ 在 $[-1,1]$ 进行采样，给采样点施加高斯噪声后试用多项式进行拟合。分别使用随机梯度下降和共轭梯度下降作为优化器进行实验，并修改训练轮次，多项式次数，学习率和是否加入L2正则项进行对比分析。

本课程实验本人都使用 `cpp` 自行搭建计算平台，代码在该仓库下，[点击链接](#)即可访问，lab 文件夹下为每个实验的代码，其余部分为搭建的计算平台。

1.2 实验原理

1.2.1 随机梯度下降

设 $x_i \in [-1,1]$ ，训练样本 $y_i = \sin(\pi x_i) + \varepsilon_i$ ，其中 $\varepsilon_i \sim N(0, \sigma^2)$ 。用 m 次多项式 $f(x; w) = w^0 + w^1 x + \dots + w_m x^m$ 拟合。

记残差 $e_i = f(x_i; w) - y_i$ 。设 N 为样本数，取平均平方误差，并可加入 L2 正则项：

$$J(w) = \frac{1}{2N} \sum_{i=1}^N e_i^2 + \frac{\lambda}{2} \sum_{j=1}^m w_j^2$$

其中 $\lambda \geq 0$ ， $\lambda=0$ 表示不加正则；常数项 w_0 不参与惩罚。由 $\frac{\partial e_i}{\partial w_j} = x_i^j$ ，可得：

$$\frac{\partial J}{\partial w_j} = \frac{1}{N} \sum_{i=1}^N e_i x_i^j + \lambda w_j (j = 1, \dots, m)$$

随机梯度下降每次抽取样本 i ，以 $e_i x_i^j + \lambda w_j$ 近似梯度，按 $w_j \leftarrow w_j - \eta(e_i x_i^j + \lambda w_j)$ 更新； w^0 不含正则项， η 为学习率。

1.2.2 共轭梯度下降

对于上述多项式回归问题，将参数写为 $w = [w_0, w_1, \dots, w_m]^T$ ，设计矩阵记为 X ，目标函数的梯度可写为：

$$\nabla J(w) = Aw - b$$

其中：

$$A = \frac{1}{N} X^T X + \lambda R, b = \frac{1}{N} X^T y$$

$R = \text{diag}(0, 1, \dots, 1)$ ，表示常数项 w_0 不参与正则化。

初始化梯度和搜索方向：

$$g_0 = Aw_0 - b, \quad d_0 = -g_0$$

第 k 次迭代计算步长并更新参数：

$$\alpha_k = \frac{g_k^T g_k}{d_k^T A d_k}, \quad w_{k+1} = w_k + \alpha_k d_k$$

然后更新梯度和共轭方向：

$$g_{k+1} = Aw_{k+1} - b$$

$$\beta_k = \frac{g_{k+1}^T g_{k+1}}{g_k^T g_k}, \quad d_{k+1} = -g_{k+1} + \beta_k d_k$$

重复上述过程，直到梯度足够小或达到最大迭代次数。

1.3 代码实现


Lab1 文件夹下 main.cpp 为主要运行函数，计算平台头文件在 mini_ml/include 和 mini_ml/src 下，mini_ml/include 主要是定义和轻量级代码的实现，mini_ml/src 下为实现代码。该架构预留了 cpu 并行实现和 cuda 实现的空间，为最后几个需要大量并行计算的实现留下架构空间。本次实验使用的优化器代码在 mini_ml/include/ml/opt 下。

一、实验环境

本次实验使用 c++20 标准进行编写，使用了部分 c++20 特性，例如 numbers 库等。使用了语法糖来简化代码。

二、实验结果及分析


首先研究学习率对随机梯度下降的影响，对于一个九个采样点十五次曲线拟合的情况，结果图如下：



图一 学习率对随机梯度下降的影响

容易发现学习率越高，收敛速度越快，但是损失函数值的抖动也就越大，因为学习率越高，随机噪声就会被放得更大，导致出现抖动。而曲线拟合差异并不大，因为随机梯度下降的收敛速度比较慢，即使高学习率也无法出现显著的过拟合情况。


在 sgd + l2 正则化的实验中，测量 $\lambda - loss$ 和 λ 变化的拟合曲线，如下图：



图二 λ 对随机梯度下降的影响


对比 λ 不同的曲线，容易发现 λ 越大，loss 曲线越容易进入“平台”，并且正则项会显著地抑制多项式部分的学习，让所有参数有往 0 改变的趋势。在 λ 足够大时，即使 epoch 轮数足够多，也难以出现拟合现象。 λ 较小时可以比较好地拟合。

对于不同阶数对拟合的研究，结论图如下



图三 阶数对随机梯度下降的影响


容易发现次数较低时，次数越高拟合越高；当次数比较高时，阶数对于拟合的影响并不大，因为 $x \in [-1, 1]$, x 的高次项的值实质上不能对最终的拟合值产生足够大的影响。



图四 轮数对随机梯度下降的影响

随着 epoch 增大，拟合效果越来越好，但是注意到，epoch 从 100 增长到 1000 的变化率远大于 5000 到 10000 的变化，因为 sgd 在前期的收敛速度很快，但是 epoch 越大收敛越慢，到最后几乎没有变化，远达不到过拟合的程度。这一点使用共轭梯度法可以解决。


在共轭梯度下降法中，我们可以很快地观察到过拟合的情况，共轭梯度法的拟合效果随 epoch 数量变化如下：



图五 轮数对共轭梯度下降的影响


不难看出，共轭梯度下降的收敛速度非常迅速，并且很容易过拟合，在 7epoch 时就出现过拟合，远快于随机梯度下降。在 5epoch 左右拟合得最好。

我们把过拟合的图像单图抽出现，发现曲线几乎过了所有点，但是曲线在采样点外的泛化能力非常差




图六 共轭梯度下降过拟合情况

为了防止共轭梯度下降出现过拟合情况，我们有两个思路，一个是增加采样点数量，另一个是增加 L2 正则化。增加采样点数量的方案中，为了控制变量，代码保证了小数量的点集一定包含于大点集，图像如下：



图七 采样点数量对于共轭梯度下降的影响
引入 L2 正则项同样可以减轻正则化，图如下：



图八 L2 正则化参数对于共轭梯度下降的影响

可以发现 λ 较小时就能够避免过拟合，但是偏大时会把参数往 0 拉，抑制拟合，出现铅笔盒。小 λ 就可以有效抑制过拟合，说明这是非常有效的。

三、 结论

本实验使用多项式对带有高斯噪声的正弦曲线进行拟合，并分别采用随机梯度下降和共轭梯度下降进行优化。实验结果表明，随机梯度下降的收敛过程较为平缓，学习率增大可以提高收敛速度，但同时会加剧 loss 的波动；随着训练轮数增加，拟合效果逐渐改善，但后期收敛速度明显降低。多项式阶数过低时会出现欠拟合，而阶数较高后继续增加阶数对拟合效果的改善有限。

相比之下，共轭梯度下降的收敛速度明显更快，能够在较少的迭代次数内获得较好的拟合效果，但也更容易快速拟合训练数据中的噪声，在本实验中约 5 个 epoch 时拟合效果较好，而继续训练后出现明显过拟合。增加训练样本数量能够改善模型的泛化能力，引入 L2 正则化也可以有效抑制高阶多项式参数过大，从而减轻过拟合，但正则化系数过大时又会造成拟合能力下降。总体来看，模型的最终效果不仅与优化方法有关，还受到学习率、训练轮数、多项式阶数、样本数量以及正则化强度等因素的共同影响，需要根据实际情况进行合理选择。